中山大學
SUN YAT-SEN UNIVERSITY

国家超级计算广州中心
NATIONAL SUPERCOMPUTER CENTER IN GUANGZHOU

多核程序设计与实践

线程执行模式与原子操作

陶钧

taoj23@mail.sysu.edu.cn

中山大学 数据科学与计算机学院

国家超级计算广州中心

课程提纲

- 线程执行模型
- 原子操作与同步

线程执行模型

- 逻辑视图
  - 每个线程块由一个SM执行
  - 由硬件调度
  - 无法控制线程块的执行顺序

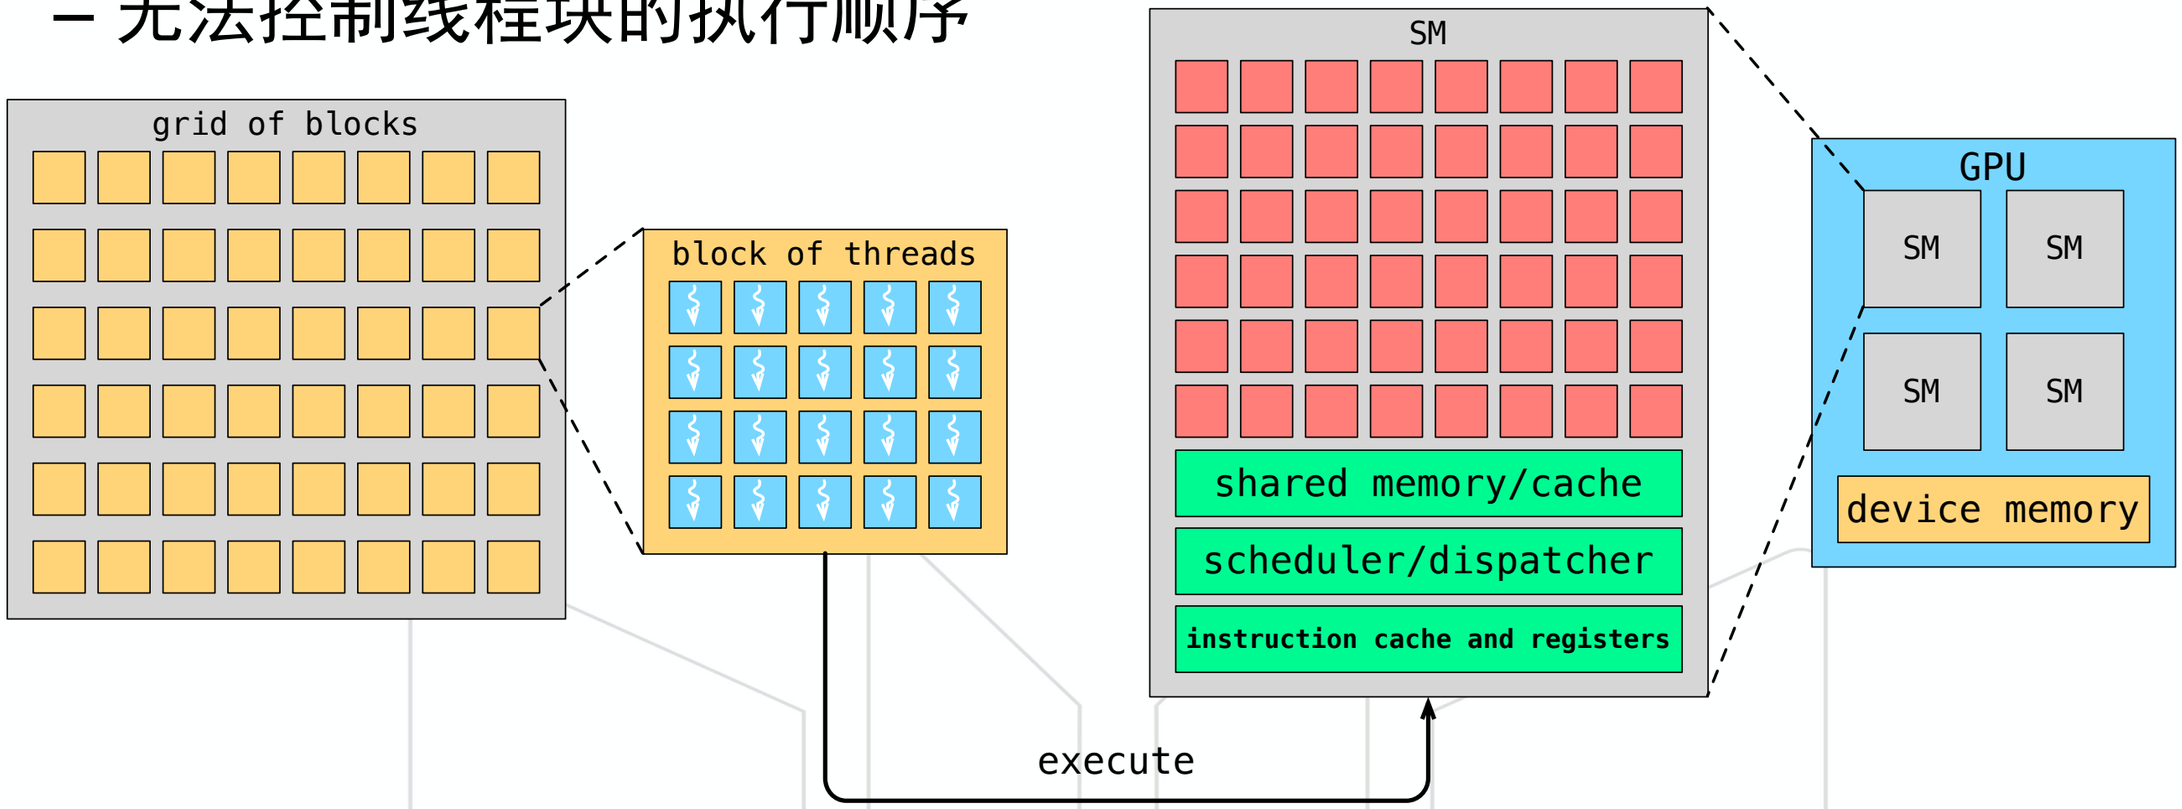

线程执行模型

- 硬件视图
  - 所有线程块在硬件上都是一维
  - 三维线程将沿x→y→z顺序展开到一维
    - `threadIdx.z*blockDim.y*blockDim.x+threadIdx.y*blockDim.x+threadIdx.x`
  - 展开后的一维线程每32个形成一个线程束
    - 最后不足32的部分也将创建线程
      - 不活跃
      - 仍将消耗SM资源

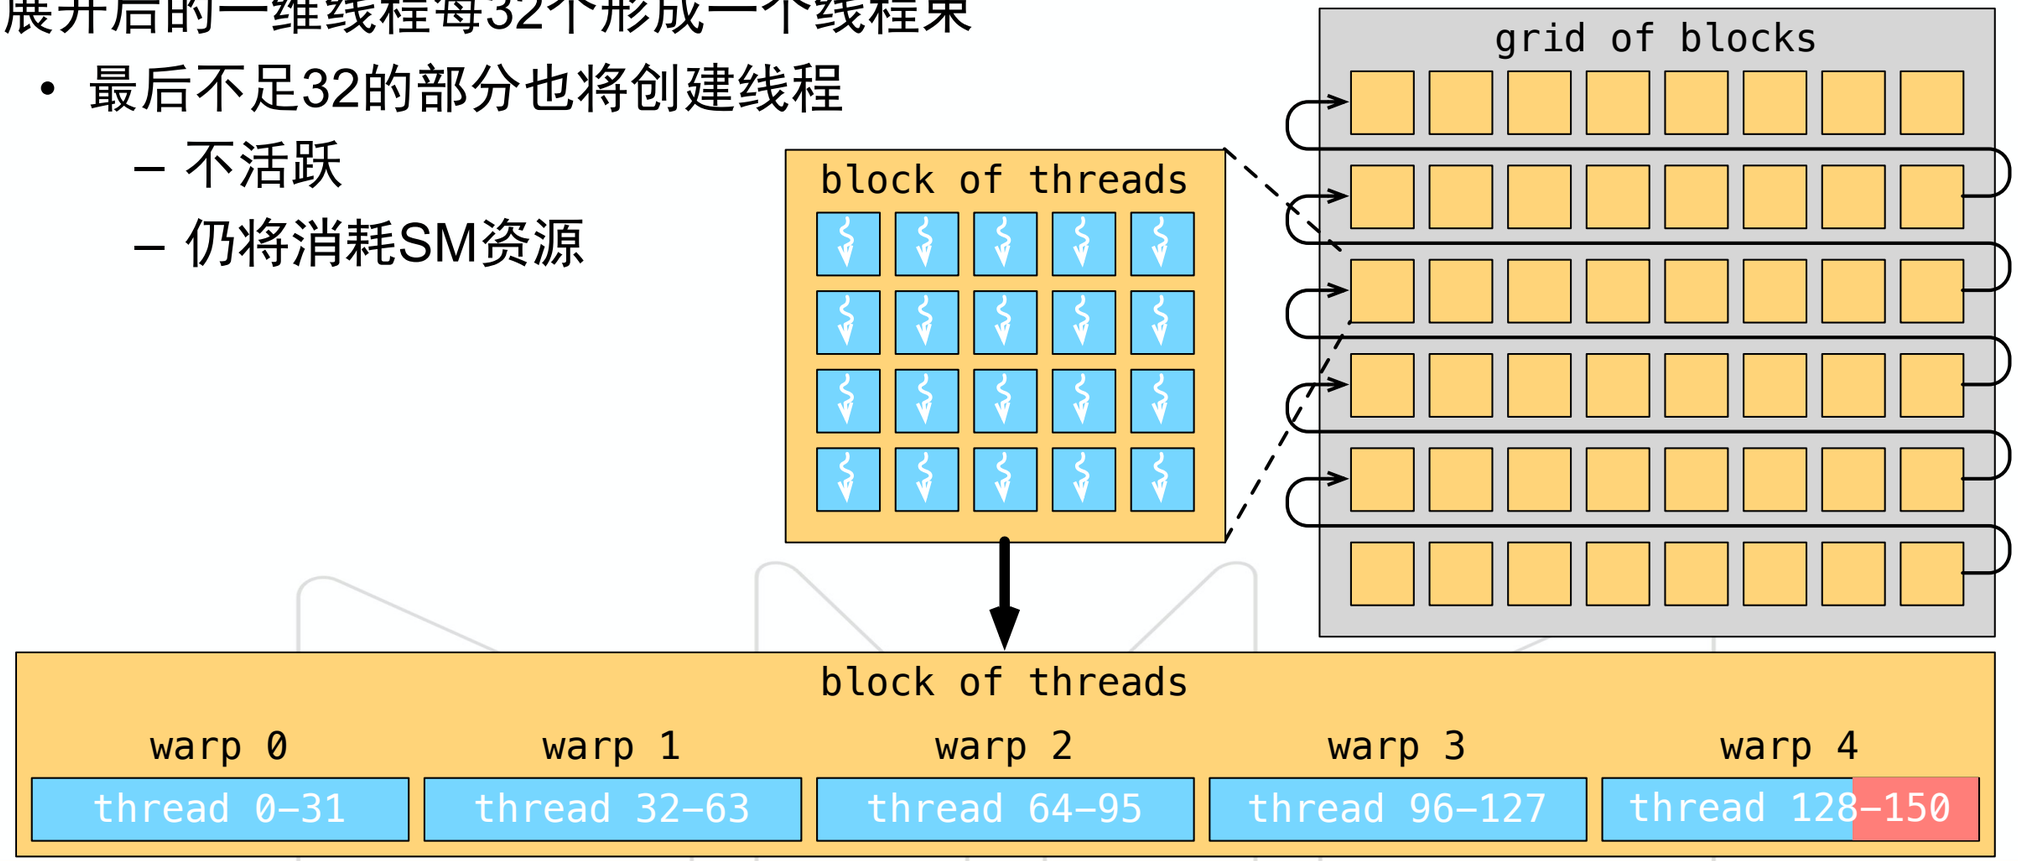

线程执行模型

线程束调度

- 线程束切换开销为0
  - SM保存每个线程束的执行上下文
  - 在整个线程束的生存周期中保存于芯片内
  - 上下文切换没有损失
  - 可切换同一SM上不同线程块的线程束
- SM中常驻线程块数量受可用资源限制
  - 资源：程序计数器、寄存器、共享内存
  - 活跃线程束：具备计算资源（寄存器、共享内存等）的线程束
    - Kepler上最大为64
    - 选定的线程束：被调度到执行单元的线程束（Kepler上最大为4）
    - 符合条件的线程束：准备执行但尚未执行
    - 阻塞的线程束：没做好执行准备（参数未就绪、无可用CUDA核心）

线程执行模型

- 线程束执行
  - 每一个线程束以SIMD方式在SM上执行
    - 线程束内同时执行同样语句
    - 线程束外的视角看来为SIMT
  - 分支分化（branch divergence）
    - 线程束出现不同的控制流

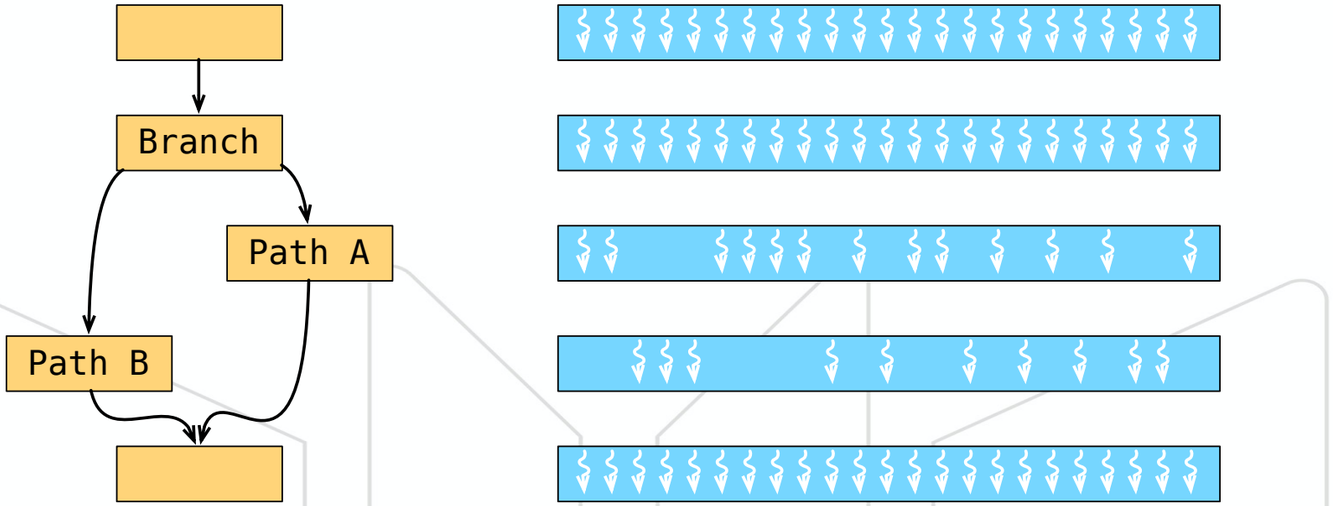

线程执行模型

线程束执行

– 以下代码哪个会出现分支分化？

```
__global__ void kernel_a(){
    if (blockIdx.x % 2) {
        do_something();
    } else {
        do_something_else();
    }
}
```

```
__global__ void kernel_b(){
    if (threadIdx.x % 2) {
        do_something();
    } else {
        do_something_else();
    }
}
```

线程执行模型

- 线程束执行
  - 分支数与效率

```
__global__ void kernel(){
    switch(threadIdx.x%N){
        case (0):
            do_case_0();
            break;
        case (1):
            do_case_1();
            break;
        ...
    }
}
```

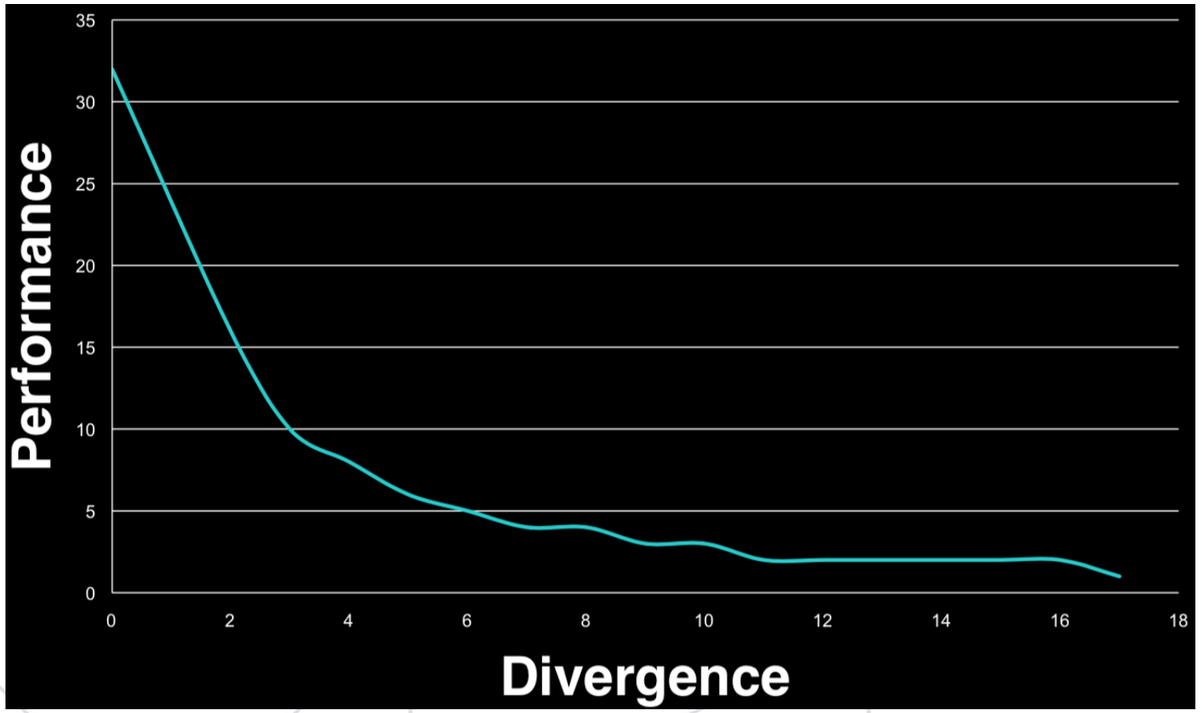

图片来自NVIDIA

线程执行模型

- 线程束执行
  - busy waiting vs signal
    - busy waiting: 如，使用while循环不断检查条件是否满足
    - signal：当条件满足由系统发送指令
    - 现实生活中都很常见：如等飞机
    - busy waiting 的问题是？

```
__global__ void kernel_a(){
    if (threadIdx.x!=0){
        while (not_ready){
            //do nothing but wait
        }
    } else {
        set_ready();
    }
}
```

```
__global__ void kernel_b(){
    if(threadIdx.x==0){
        set_ready();
    }
    __syncthreads();
}
```

线程执行模型

- 线程束执行
  - 条件语句 vs 条件赋值
    - C代码

```
if (i<n){
    a = 1;
} else {
    a = 2;
}
```

```
a = (i<n)?1:2;
```

线程执行模型

线程束执行

– 条件语句 vs 条件赋值

- C代码

```
if (i<n){
    a = 1;
} else {
    a = 2;
}
```

```
a = (i<n)?1:2;
```

- PTX (Parallel Thread eXecution) ISA 指令级源码

```
     mov.s32 a, 0; //a=0
     setp.lt.s32 p, i, n; //p=(i<n)
@p   mov.s32 a, 1; //a=1
@!p  mov.s32 a, 2; //a=2
```

```
mov.s32 a, 0; //a=0
setp.lt.s32 p, i, n; //p=(i<n)
selp a, 1, 2, p; //a=(p)?1:2
```

线程执行模型

线程束执行

- 减少分支分化的影响
  - 减少判断语句
    - 尤其是减少基于threadIdx的判断语句
      - » 判断语句不必然导致分支分化
    - 使用条件语句代替条件赋值

```
if (threadIdx.x < RADIUS) {
    smem[sid-RADIUS] = in[tid-RADIUS];
    smem[sid+BDIM] = in[tid+BDIM];
}
```

```
if (threadIdx.x < RADIUS) {
    smem[sid-RADIUS] = in[tid-RADIUS];
} else if (threadIdx.x > BDIM-RADIUS) {
    smem[sid+RADIUS] = in[tid+RADIUS];
}
```

  - 平衡分支执行时间
    - 避免出现执行时间过长的分支

课程提纲

- 线程执行模型
- 原子操作与同步

原子指令与同步

- 原子指令
  - 执行过程不能分解为更小的部分：不被中断
  - 避免竞争条件出现（回顾讲义3：OpenMP）
  - 竞争条件（race condition）
    - 程序运行结果依赖于不可控的执行顺序
- OpenMP计算直方图例子中
  - 使用临界区或原子指令避免对histogram的更新出现竞争条件

```
#pragma omp parallel for
for(int i=0; i<1000; ++i){
    int value = rand()%20;

    #pragma omp critical
    {
        histogram[value]++;
    }
}
```

```
#pragma omp parallel for
for(int i=0; i<1000; ++i){
    int value = rand()%20;
    #pragma omp atomic
    histogram[value]++;
}
```

原子操作与同步

- CUDA原子操作
  - 加减：`atomicAdd()`, `atomicSub()`, `atomicInc()`, `atomicDec()`
  - 比较与交换：`atomicMin()`, `atomicMax()`, `atomicExch()`, `atomicCAS()`
  - 位运算：`atomicAnd()`, `atomicOr()`, `atomicXor()`
  - 支持的原子操作依据GPU架构而异
    - 计算能力1.0的设备不支持全局内存上的原子操作
      - 无法同步所有线程

原子操作与同步

- CUDA原子操作
  - 基础操作：**atomicCAS()**
    - 其他所有原子操作均可由**atomicCAS()**实现
    - **CAS：compare and swap**
      - 读取目标位置（address）并于预期值（old_val）进行比较
        - » 相等则将new_val写入目标位置
        - » 不等则不发生变化
      - 返回目标位置中原值：可用来检查CAS操作是否成功

```
int compare_and_swap(int* address, int old_val, int new_val){
    int old_reg_val = * address;

    if(old_reg_val == old_val) {
        * address = new_val;
    }

    return old_reg_val;
}
```

原子操作与同步

- CUDA原子操作
  - 基础操作：**atomicCAS()**
    - 例：使用**atomicCAS()**实现**atomicAdd()**

```
__device__ int my_atomicAdd(int* address, int incr){
    int expected = *address;
    int old_val = atomicCAS(address, expected, expected+incr);

    while (old_val != expected) {
        expected = old_val;
        old_val = atomicCAS(address, expected, expected+incr);
    }

    return old_val;
}
```

原子操作与同步

- CUDA原子操作应用举例：动态工作队列
  - 使用计数器动态获取工作
    - 增加负载平衡？

```
__global__ void work_queue(int* work_q, int* q_counter,
                           int* output, int queue_max)
{
    int local_counter = 0;
    do {
        int qid = atomicInc(q_counter, queue_max);
        output[qid] = work(work_q[qid]);
        ++local_counter;
    } while (qid!=0 && local_counter!=N);
}
```

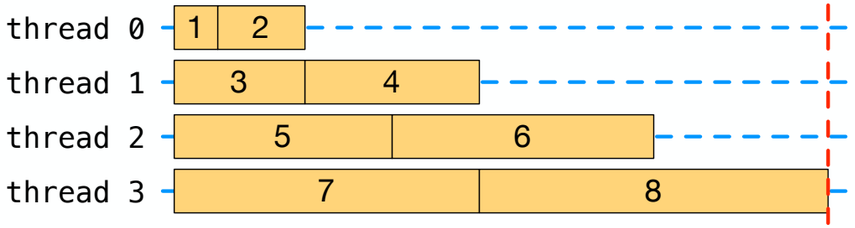

注意 atomicInc 中第二个参数不是增加量：
（可由 atomicAdd 替代）

```
atomicInc (address, val):
((*address>=val) ? 0 : (*address+1))
```

原子操作与同步

- CUDA原子操作应用举例：计算直方图
  - 最直接的思路：
    - 使用**atomicAdd**给histogram中相应值每次增加1

```
__global__ void histogram(int *histogram, int* val){
    int tid = blockIdx.x*blockDim.x + threadIdx.x;
    int val_i = val[tid];
    atomicAdd(&histogram[val_i], 1);
}
```

    - 问题？

原子操作与同步

- CUDA原子操作应用举例：计算直方图
  - 最直接的思路：
    - 使用**atomicAdd**给histogram中相应值每次增加1

```
__global__ void histogram(int *histogram, int* val){
    int tid = blockIdx.x*blockDim.x + threadIdx.x;
    int val_i = val[tid];
    atomicAdd(&histogram[val_i], 1);
}
```

    - 问题：高度串行化

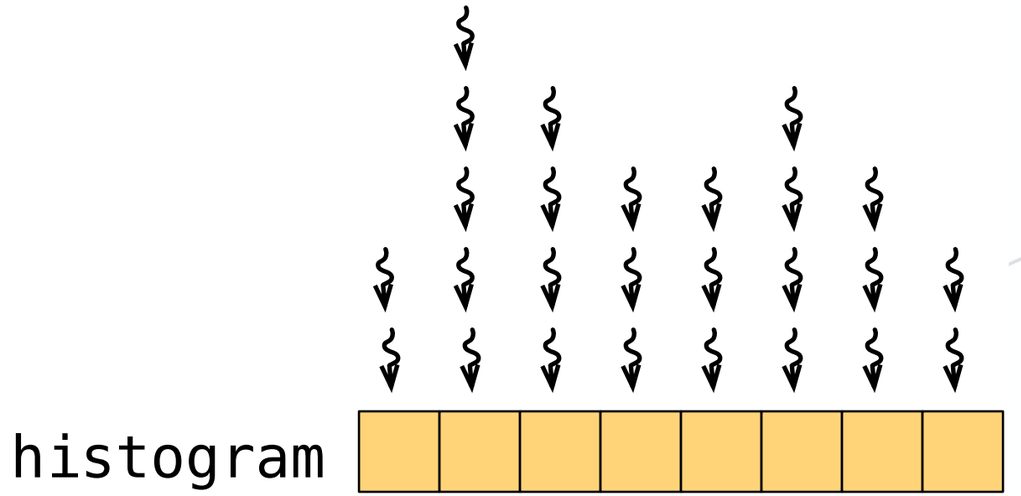

- CUDA原子操作应用举例：计算直方图
  - 改进方法：使用共享内存
    - 每个线程块先更新本地直方图
    - 所有线程更新结束后，一次写入全局直方图

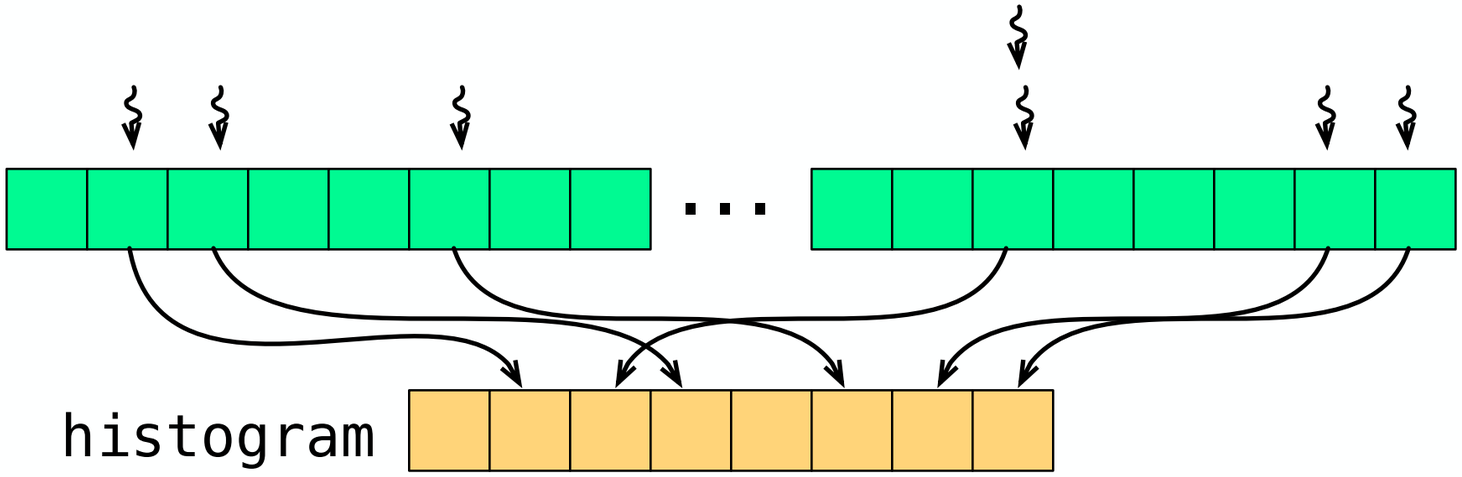

- CUDA原子操作应用举例：计算直方图
  - 改进方法：使用共享内存

```
__global__ void histogram(int *histogram, int* val){
    int tid = blockIdx.x*blockDim.x + threadIdx.x;
    __shared__ int local_hist[N];

    if (tid < N) {
        local_hist[tid] = 0;
    }
    __syncthreads();

    int val_i = val[tid];
    atomicAdd(&local_hist[val_i], 1);
    __syncthreads();

    if (tid < N && local_hist[tid]!=0) {
        atomicAdd(&histogram[tid], local_hist[tid]);
    }
}
```

- CUDA原子操作应用举例：计算直方图
  - 是否能不使用原子操作？
    - 利用线程束隐含的同步（早期算法）
    - 分配大小为 m*N 的共享内存
      - 其中为 m 为一个线程块中线程束的个数
      - 每个线程束写入独立的local copy

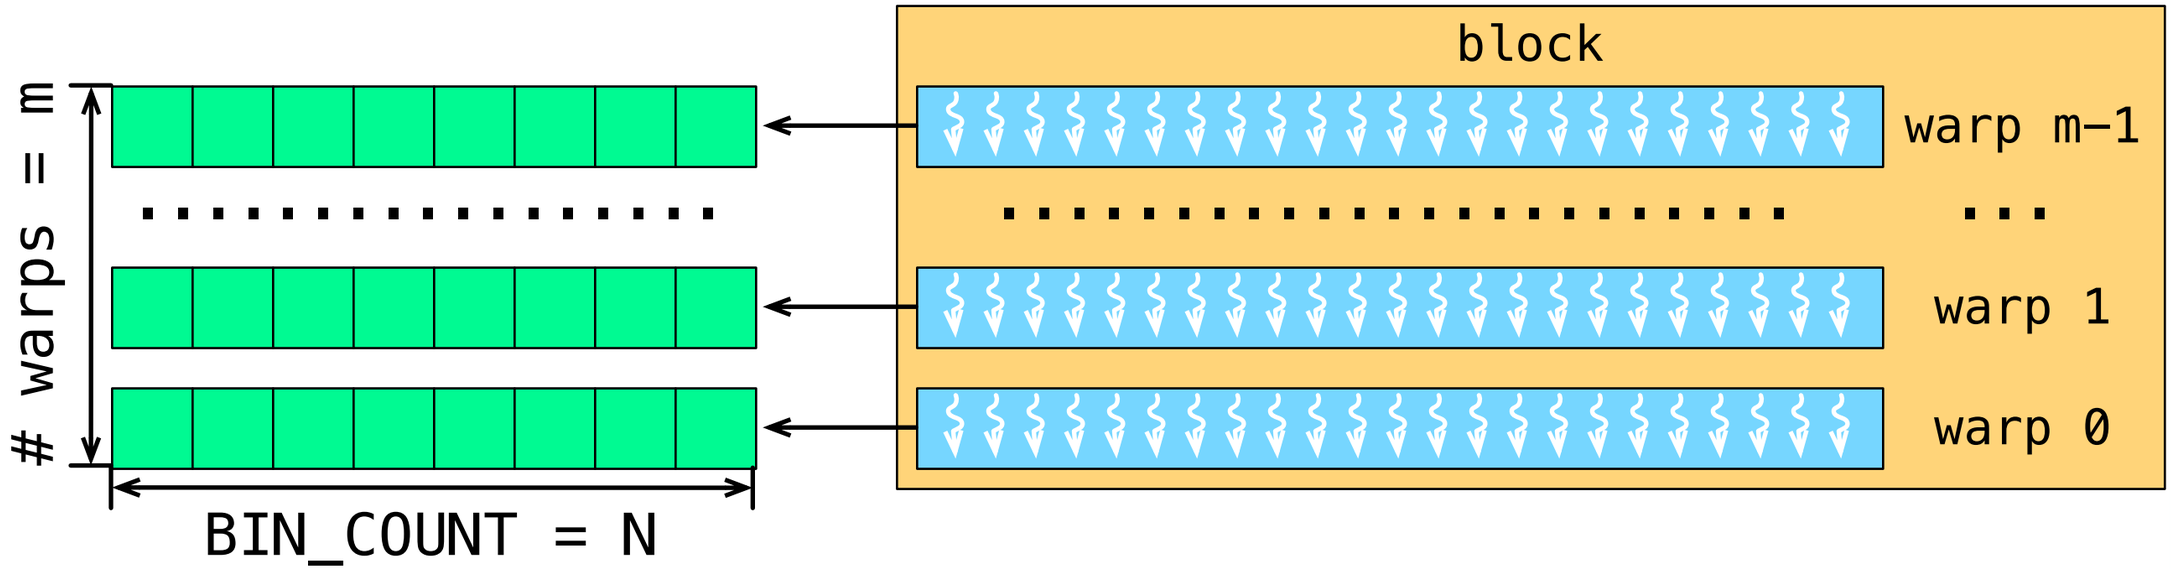

原子操作与同步

CUDA原子操作应用举例：计算直方图

- 不使用原子操作：利用线程束隐含的同步（早期算法）
  - 如何保证线程束之间的线程不产生竞争状态？
    - 线程实际处于同步状态，需要知道的只是最后写入的线程

```
__device__ void addData(
    volatile unsigned int *s_WarpHist,
    unsigned int data,
    unsigned int threadTag)
{
    unsigned int count;
    do{
        count = s_WarpHist[data] & 0x07FFFFFU;
        count = threadTag | (count + 1);
        s_WarpHist[data] = count;
    } while (s_WarpHist[data] != count);
}
```

```
volatile unsigned int *s_WarpHist
: volatile 是否可以省略?
```

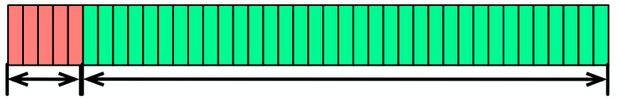

threadTag (5 bits)　　count (27 bits)

标记修改内存的线程Id　　直方图中的实际计数

原子操作与同步

- CUDA原子操作应用举例：元素归类
  - 在计算直方图的基础上，记录每个bin中的元素
  - 直接思路：使用N个数组，每次将元素置于相应数组末端
    - N为bin的数目

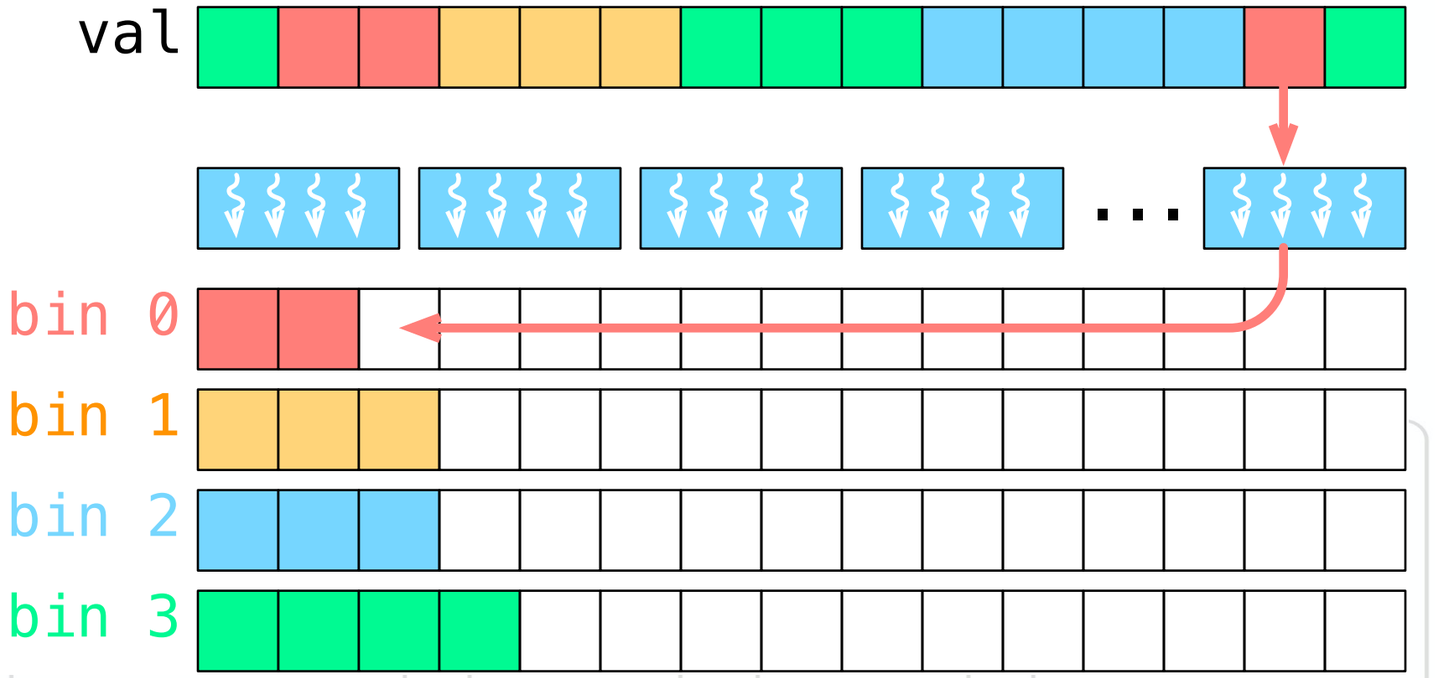

原子操作与同步

CUDA原子操作应用举例：元素归类

- 在计算直方图的基础上，记录每个bin中的元素
- 直接思路：使用N个数组，每次将元素置于相应数组末端
  - N为bin的数目

```
__global__ void classify(int *output, int* bin_size, int* val, int m){
    int tid = blockIdx.x*blockDim.x + threadIdx.x;

    int val_i = val[tid];
    int bin = compute_bin(val_i);

    int pos = atomicInc(&bin_size[bin], m);
    output[bin*m+pos] = val_i;
}
```

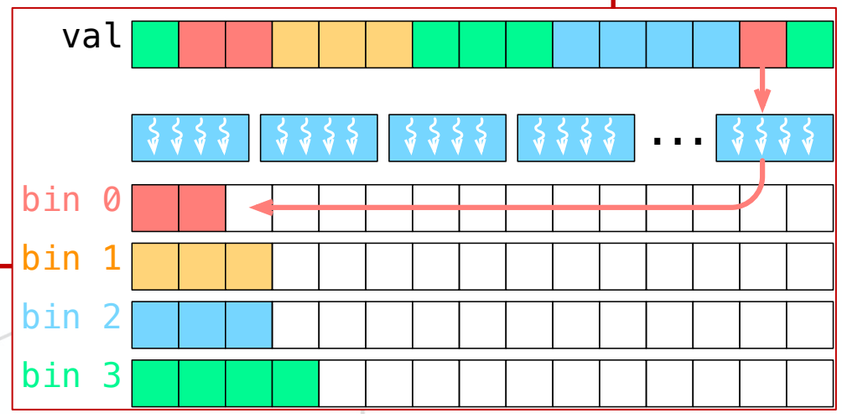

原子操作与同步

- CUDA原子操作应用举例：元素归类
  - 在计算直方图的基础上，记录每个bin中的元素
  - 改进空间算法：使用链表

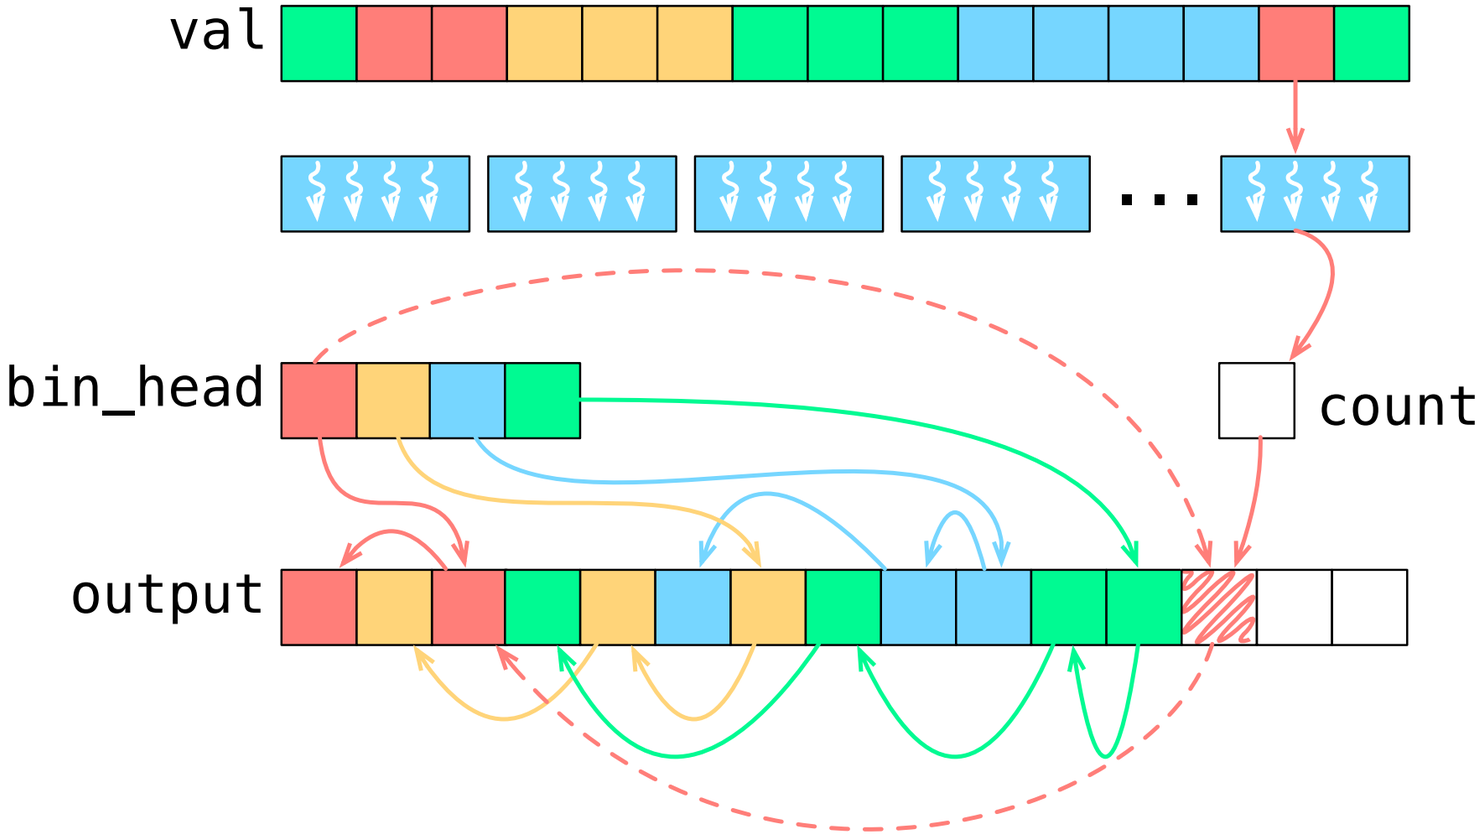

原子操作与同步

- CUDA原子操作应用举例：元素归类
  - 在计算直方图的基础上，记录每个bin中的元素
  - 改进空间算法：使用链表

```
__global__ void classify(OutputType *output, int *count,
                         int* bin_head, int* val, int m){
    int tid = blockIdx.x*blockDim.x + threadIdx.x;

    int val_i = val[tid];
    int bin = compute_bin(val_i);

    int pos = atomicInc(count, m);
    int prev_pos = atomicExch(&bin_head[bin], pos);

    OutputType ret = {val_i, prev_pos};
    output[bin*m+pos] = ret;
}
```

```
typedef struct {
    int val;
    int prev_ptr;
} OutputType;
```

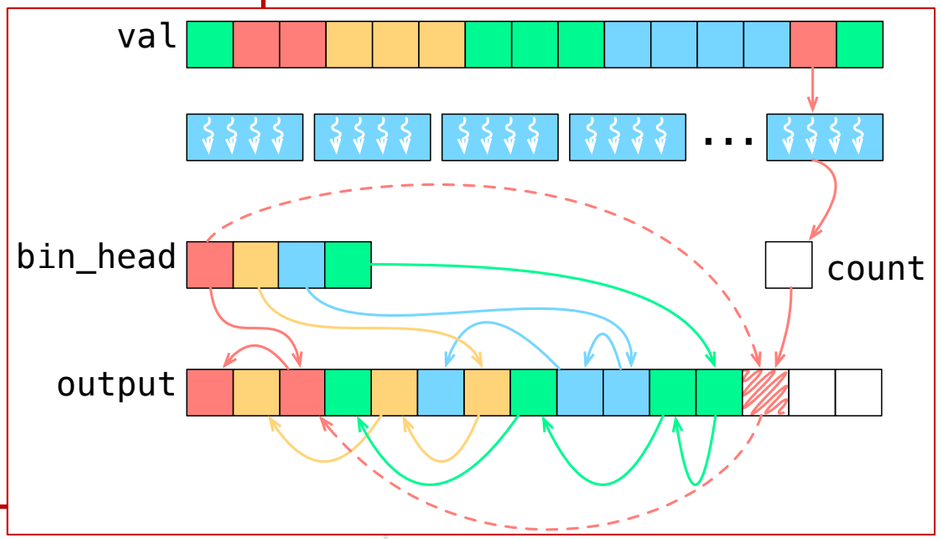

原子操作与同步

- CUDA原子操作应用举例：元素归类
  - 在计算直方图的基础上，记录每个bin中的元素
  - 使用空间对比
    - 直接思路：bin_size(N)+output(m*N)
    - 链表：bin_head(N)+output(2*m)+count(1)

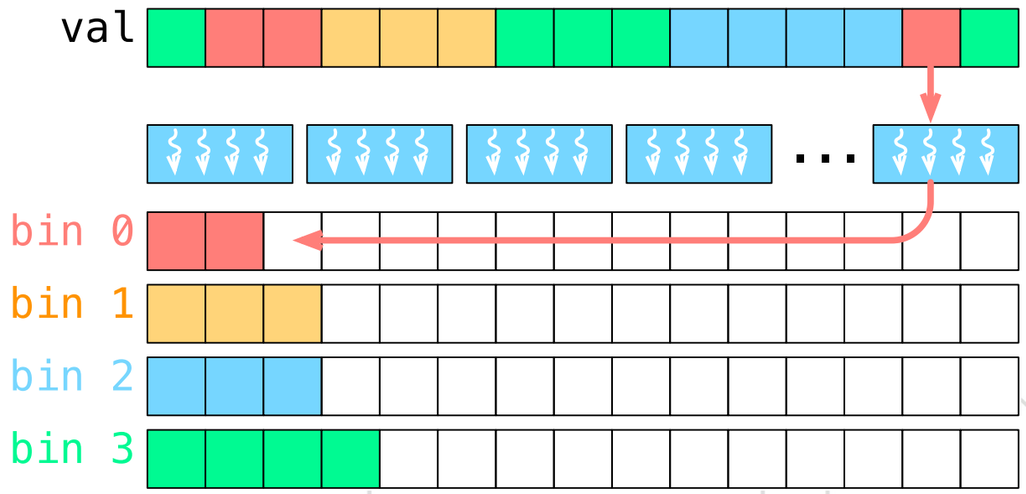

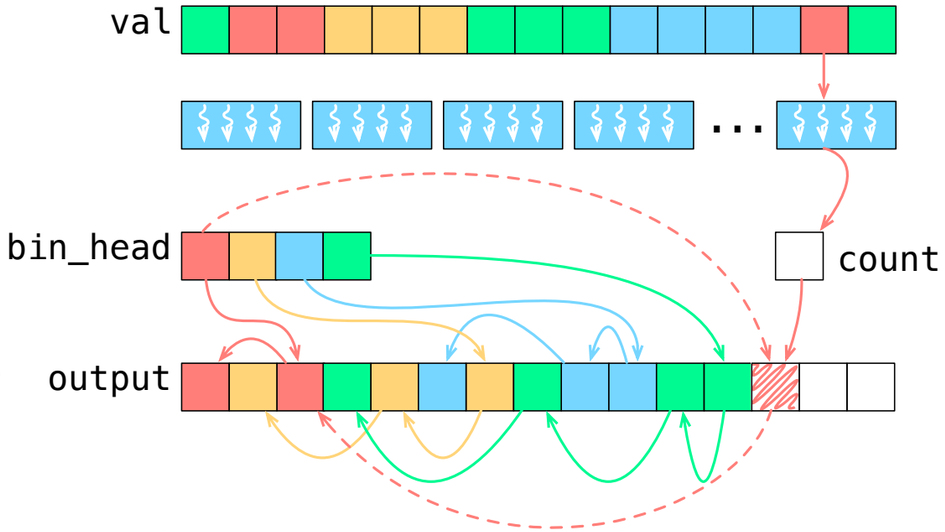

原子操作与同步

- CUDA同步机制
  - 核函数调用结束时同步
    - 在host线程中使用`cudaDeviceSynchronize()`
    - 同步网格中所有线程
  - 线程束中同步
    - 隐含的同步执行
  - 使用原子操作？

原子操作与同步

- 使用原子操作实现原子锁
  - 开锁状态：mutex = 0
  - 锁状态：mutex = 1
  - 使用while循环与atomicCAS()不断检查，直到锁处于打开状态
  - 需注意是否会导致死锁
    - 同一线程束内（最好）只使用一个线程执行开锁解锁操作
    - 使用额外操作保证线程束内原子操作/临界区状态

```
int *mutex;

__device__ void lock(int* mutex){
    while (atomicCAS(mutex, 0, 1)!=0);
}
```

```
__device__ void unlock(int* mutex){
    atomicExch(mutex, 0);
}
```

原子操作与同步

- 原子操作并不解决所有与执行顺序相关的问题
  - 原子操作不指明执行顺序
  - 例：精度损失

$$1.23456 \times 10^{30} + 9.87654 \times 10^{-30} - 1.23456 \times 10^{30}$$
$$1.23456 \times 10^{30} - 1.23456 \times 10^{30} + 9.87654 \times 10^{-30}$$

  - 串行程序也存在此类问题，但执行顺序相对容易控制
    - 例如，先对绝对值大小进行排序，再相加
  - 在并行计算过程中需要更谨慎

小结

- 线程执行模型
  - 在硬件视角中，线程块始终为在一维上排列的一组线程
  - 每32个线程形成一个线程束
  - 线程束为同步执行
  - 线程束在执行中遇到控制流将出现产生分支
- 原子操作与同步
  - 基本原子操作
    - `atomic{Add, Sub, Inc, Dec, Min, Max, Exch, CAS, And, Or, Xor}`
  - 提升效率：避免大量原子操作同时作用于同一数据
  - 原子操作实现原子锁

Questions?