



中山大學
SUN YAT-SEN UNIVERSITY



国家超级计算广州中心
NATIONAL SUPERCOMPUTER CENTER IN GUANGZHOU

多核程序设计与实践

并行编程模式

陶钧

taoj23@mail.sysu.edu.cn

中山大学 数据科学与计算机学院
国家超级计算广州中心

- 归约算法
- 扫描算法

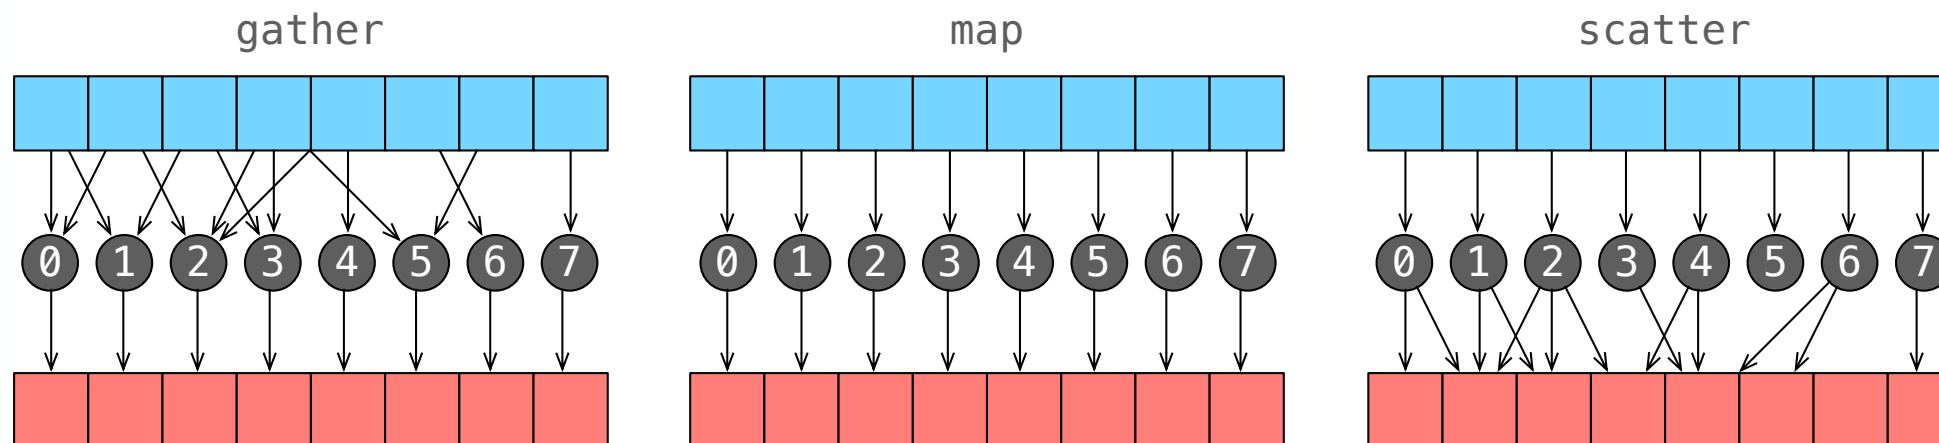
并行模式

– 并行程序的高级抽象

- 不关心具体的数据类型或操作
- 描述并行编程中共有的模式（pattern）
- 对比抽象代数

常见并行模式

– gather, scatter, map, stencil, reduce, scan, sort, segmented-scan, map-reduce



归约 (reduction)

- 对传入的 $O(n)$ 个输入数据，使用二元操作 \oplus 符生成 $O(1)$ 个结果
 - 二元操作符 \oplus 需满足结合律
 - 例如，求最小值，最大值，求和，平方和，逻辑与，逻辑或，等
 - OpenMP中提供并行 reduction (讲义3)


```
#pragma omp for reduction(+: total)
for(int i=0; i<20; ++i){
    total += histogram[i];
}
```



• CPU串行归约



– 执行时间 $O(n)$

```
int data[N];  
int r;  
  
for (int i=0; i<N; ++i){  
    r = reduce(r, data[i]);  
}
```



GPU归约：二叉树


- 二元操作符 \oplus 需满足结合律
 - 结果与执行顺序无关
- 执行时间 $O(\lg n)$



例子：数组求和

– 将前例中CPU中二元操作符 \oplus 定义为整型相加


```
int sum(int* data){  
    int r = 0;  
    for(int i = 0; i < N; ++i){  
        r = reduce(r, data[i]);  
    }  
}  
  
int reduce(int r, int i){  
    return (r+i);  
}
```



- 例子：数组求和
 - GPU并行求和

```
__global__ void sum_reduction(float* out, float* data){  
    int tid = blockIdx.x*blockDim.x+threadIdx.x;  
    out[tid] = data[tid*2] + data[tid*2+1];  
}
```


out可以等于data吗?



kernel launch 0

kernel launch 1

kernel launch 2



- 例子：数组求和
 - GPU并行求和

```
__global__ void sum_reduction(float* out, float* data){  
    int tid = blockIdx.x*blockDim.x+threadIdx.x;  
    out[tid] = data[tid*2] + data[tid*2+1];  
}
```

- 以上代码存在问题：
 - 需要在全局内存中额外分配内存存储中间结果（out）
 - » 大小为 $0.5*n+0.25*n$
 - » 全局内存访问慢
 - 线程工作量小（需产生大量线程）

例子：数组求和

– GPU并行求和（共享内存）

```
__global__ void sum_reduction(float *out, float* in, int N){
    extern __shared__ int sdata[];

    int tid = blockIdx.x*blockDim.x+threadIdx.x;
    sdata[threadIdx.x] = in[tid]; ←
    __syncthreads();

    for (int stride=1; stride<blockDim.x; stride*=2){
        int sid = threadIdx.x*2*stride;
        if (sid<blockDim.x){
            sdata[sid] += sdata[sid+stride];
        }
        __syncthreads();
    }

    if (threadIdx.x==0){
        out[blockIdx.x] = sdata[0];
    }
}
```

数据量大时也可以先进行一次简单的串行归约

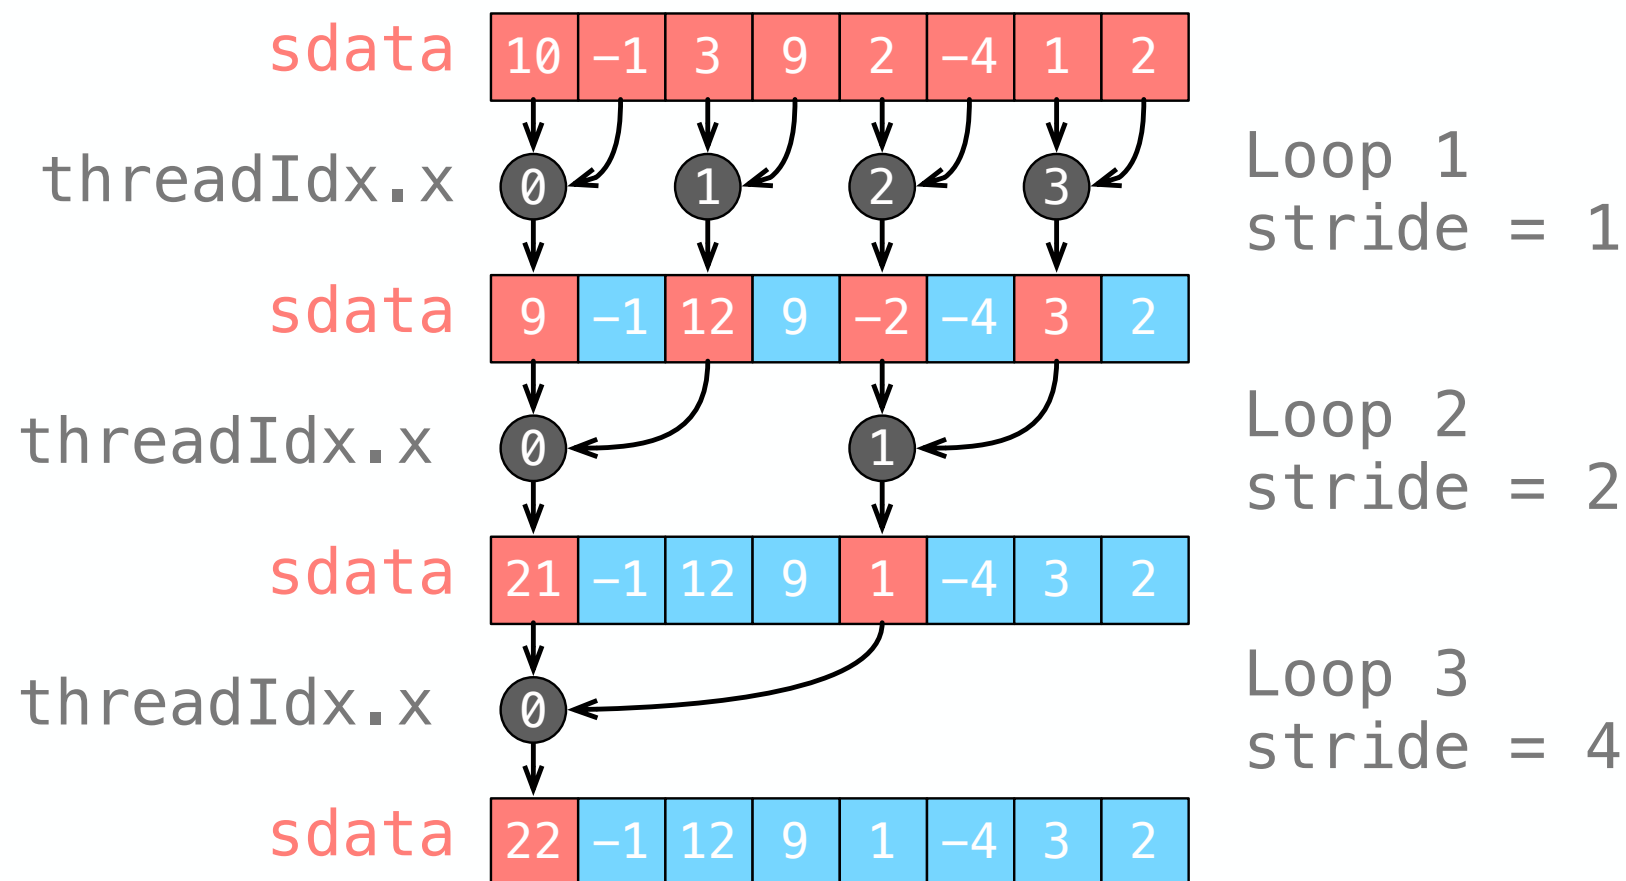
```
for(int i = tid;
    i < N;
    i+=blockDim.x)
{
    sum += in[i];
}
sdata[threadIdx.x] = sum;
```

out大小为gridDim.x

例子：数组求和

– GPU并行求和

- 共享内存
- 线程块reduction




```
for (int stride=1; stride<blockDim.x; stride<=1){  
    int sid = threadIdx.x*2*stride;  
    if (sid<blockDim.x){  
        sdata[sid] += sdata[sid+stride];  
    }  
    __syncthreads();  
}
```

例子：数组求和

– GPU并行求和

- 共享内存
- 线程块reduction



```
for (int stride=blockDim.x/2; stride>0; stride>>=1){  
    if (threadIdx.x<stride){  
        sdata[threadIdx.x] += sdata[threadIdx.x+stride];  
    }  
    __syncthreads();  
}
```

- 例子：数组求和

- GPU并行求和

- 注意：以下两种写法哪种正确？


```
for (int stride=blockDim.x/2; stride>0; stride>>=1){  
    if (threadIdx.x<stride){  
        sdata[threadIdx.x] += sdata[threadIdx.x+stride];  
    }  
    __syncthreads();  
}
```

```
for (int stride=blockDim.x/2; stride>0; stride>>=1){  
    if (threadIdx.x<stride){  
        sdata[threadIdx.x] += sdata[threadIdx.x+stride];  
        __syncthreads();  
    }  
}
```

例子：数组求和

– GPU并行求和

- 对线程块产生的结果迭代调用归约核函数
- 当n不大时，用CPU串行计算可能更有效率
 - 减少创建线程、同步等开销
- 也可以使用**atomicAdd**完成归约
 - 只需调用一次核函数（或数次无atomic的核函数加一次带atomic的核函数）



- 例子：数组求和

- GPU并行求和

- 使用**atomicAdd**完成归约

```
__global__ void sum_reduction(float *out, float* in){
    extern __shared__ int sdata[];

    int tid = blockIdx.x*blockDim.x+threadIdx.x;
    sdata[threadIdx.x] = in[tid];
    __syncthreads();

    for (int stride=blockDim.x/2; stride>0; stride>>=1){
        if (threadIdx.x<stride){
            sdata[threadIdx.x] += sdata[threadIdx.x+stride];
        }
        __syncthreads();
    }

    if (threadIdx.x==0)
        atomicAdd(out, sdata[0]);
}
```

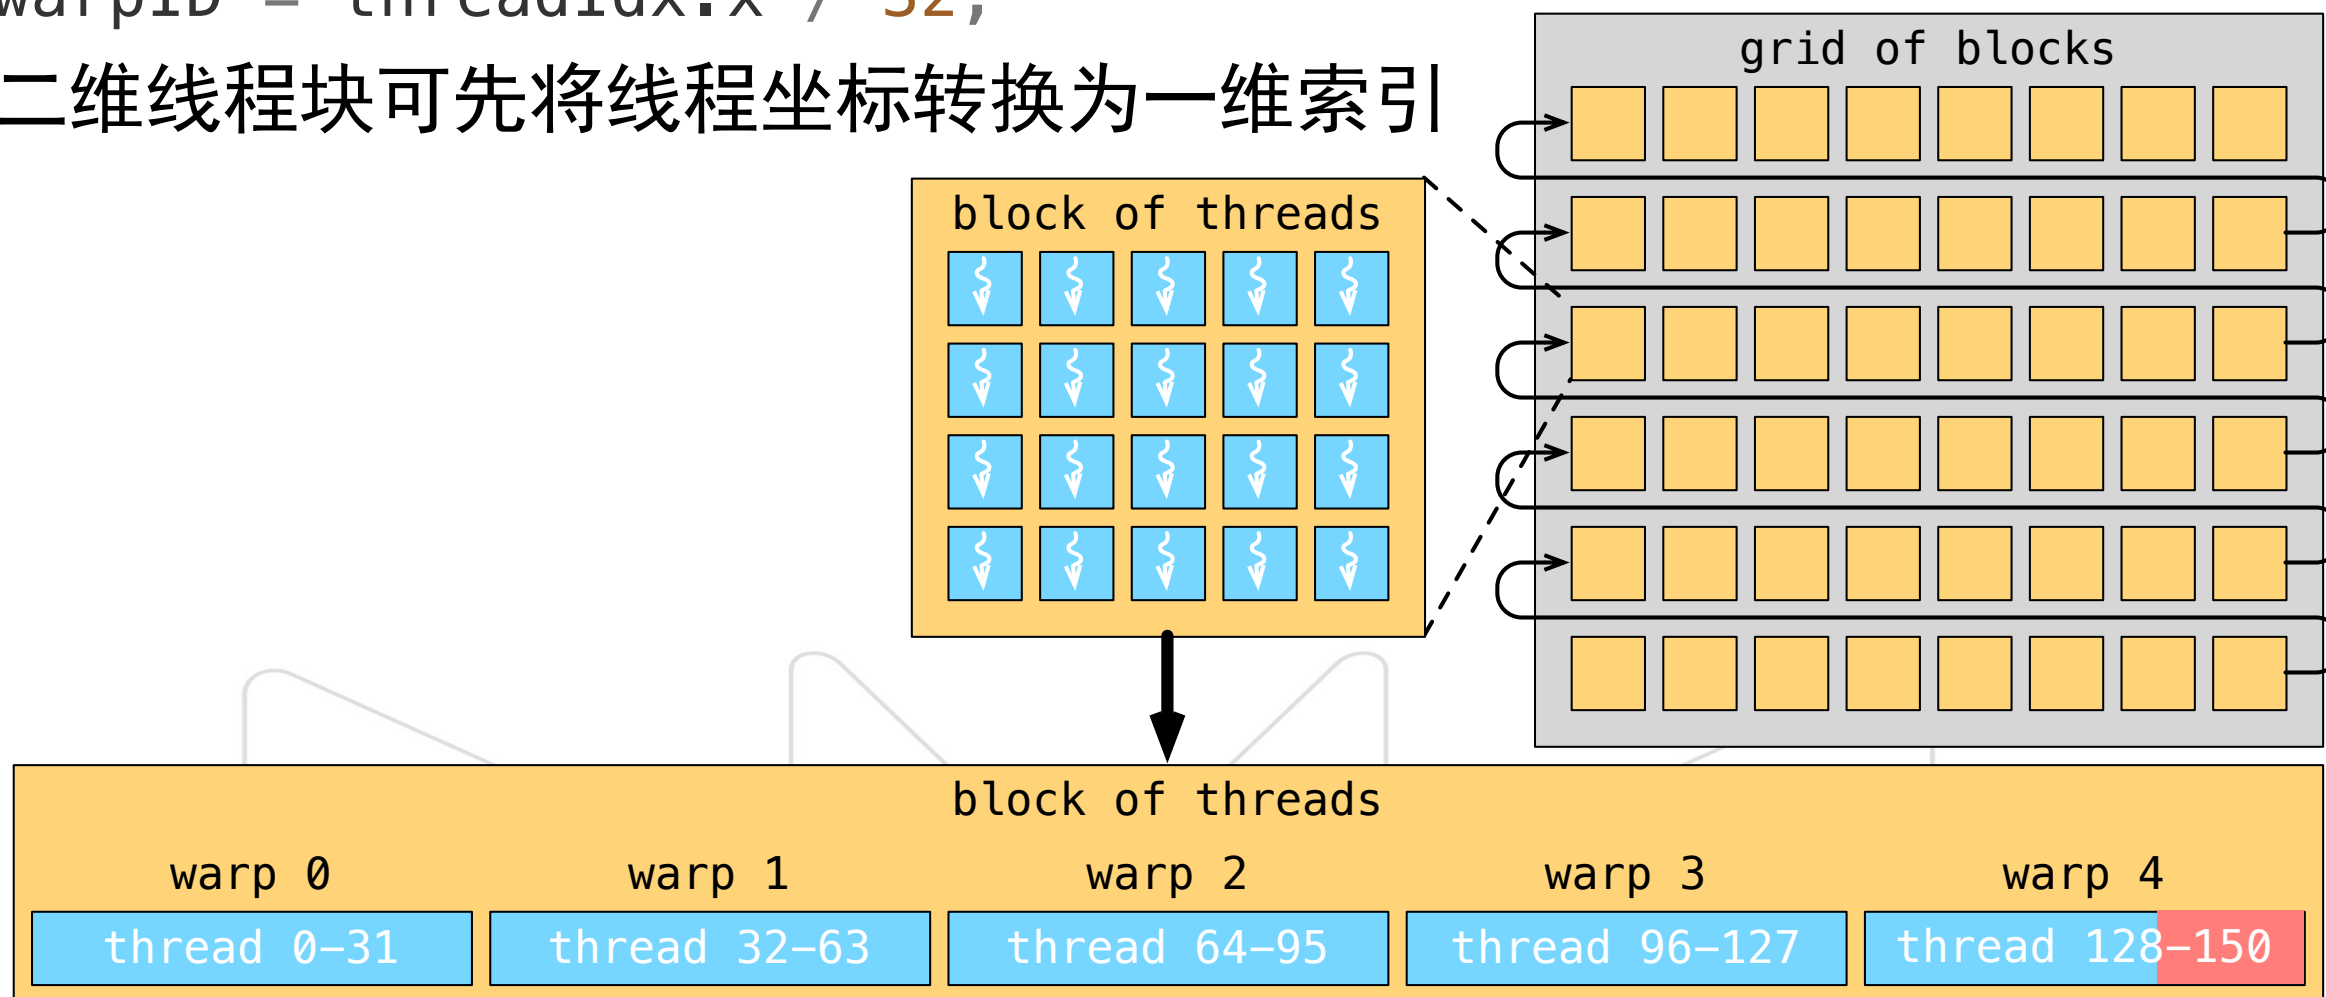
◉ 使用线程束洗牌指令

- 共享内存使线程块中线程快速交换数据
 - 必要时需要通过__syncthreads() 同步
- 洗牌指令使线程束中线程直接交换数据
 - 允许线程直接读取束内另一线程的寄存器
 - 可取代atomic操作
 - 不可置于控制流分支分流的语句中（参见课件6）
 - 不通过共享内存或全局内存
 - 比共享内存延迟更低
 - 交换不消耗额外内存
 - 隐式同步（由线程束执行模式决定）
 - 不需要使用__syncthreads() 同步
 - 需要计算能力3.0或以上（Kepler或之后架构）

使用线程束洗牌指令

– 束内线程 (lane)


- $\text{laneID} = \text{threadIdx.x} \% 32$;
- $\text{warpID} = \text{threadIdx.x} / 32$;
- 二维线程块可先将线程坐标转换为一维索引



使用线程束洗牌指令

– 四种形式的洗牌指令



- `__shfl()`, `__shfl_up()`, `__shfl_down()`, `__shfl_xor()`
- 支持 `int`, `float`, `half`
- `T __shfl(T var, int srcLane, int width=warpSize)`
 - `var`: 需要交换的变量
 - `srcLane`: 数据源的束内线程 (具体含义依赖于`width`)
 - `Width`: 交换数据的线程束的分段宽度 (需要是不超过32的2的指数)
 - 如, `__shfl(x, 2, 8)`



使用线程束洗牌指令

– 四种形式的洗牌指令


- `T __shfl_up(T var, int delta, int width=warpSize)`
- `T __shfl_down(T var, int delta, int width=warpSize)`
 - delta: 移位的偏移量



使用线程束洗牌指令

– 四种形式的洗牌指令

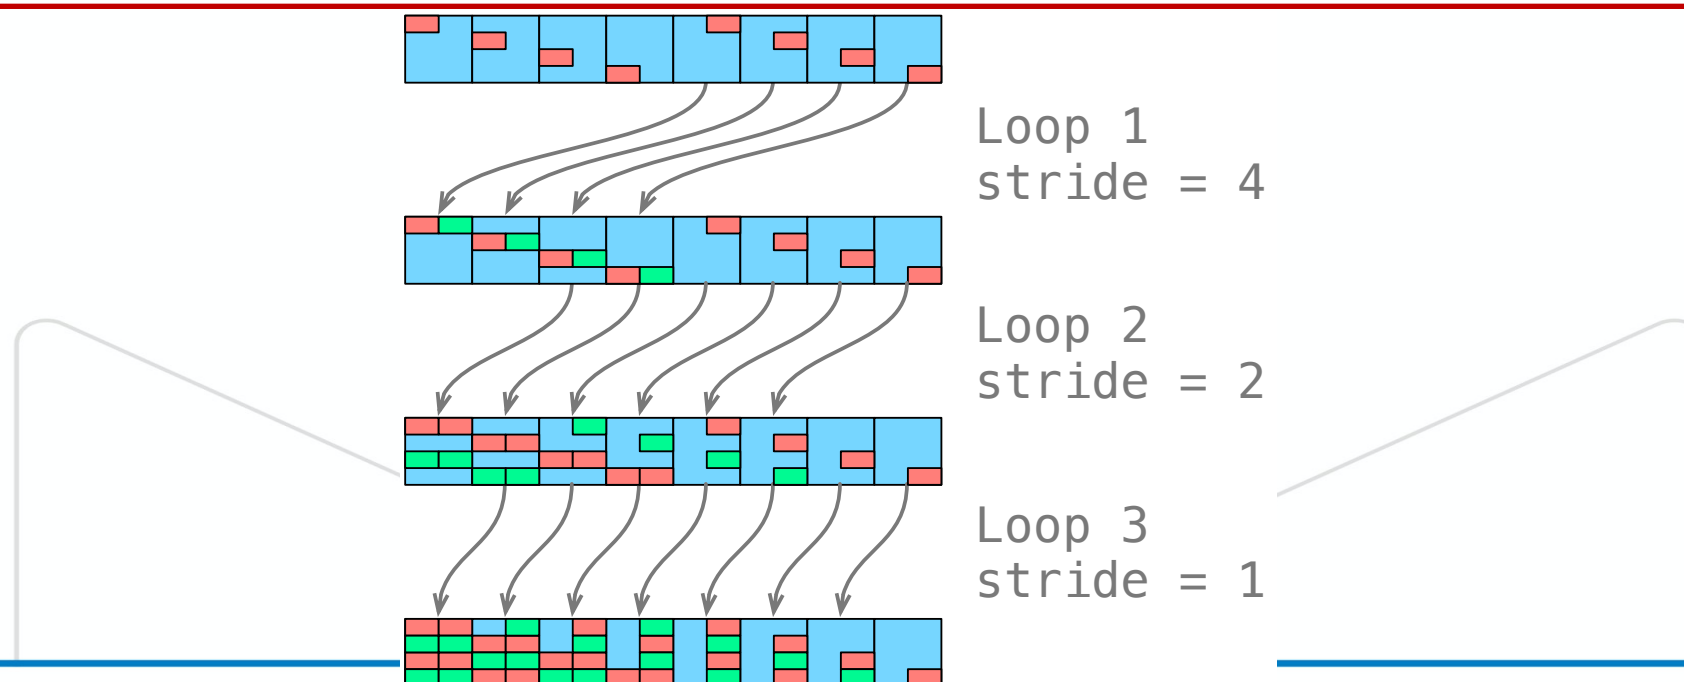
- T **__shfl_xor**(T var, int laneMask, int width=warpSize)
 - 根据束内线程自身索引按位异或来传输数据（蝴蝶交换）
 - laneMask: 指明异或的bit
 - » **__shfl**(x, 2)
 - 指明用于求异或的bit为010b
 - 0 (000b) 与 2 (010b) 交换, 1 (001b) 与 3 (011b) 交换, 以此类推



使用线程束洗牌指令

使用 `__shfl_down()` 的数组求和


```
__global__ void sum_reduction_warp(int* out, int* data, int N){  
    int local_sum = data[blockIdx.x*blockDim.x+threadIdx.x];  
  
    for (int stride = WARP_SIZE/2; stride>0; stride>>=1)  
        local_sum += __shfl_down(local_sum, stride);  
  
    if (threadIdx.x%32==0)  
        out[blockIdx.x*blockDim.x/WARP_SIZE+threadIdx.x/WARP_SIZE];  
}
```



使用线程束洗牌指令

– 使用 `__shfl_xor()` 的数组求和

```
__global__ void sum_reduction_warp(int* out, int* data, int N){  
    int local_sum = data[blockIdx.x*blockDim.x+threadIdx.x];  
  
    for (int mask = WARP_SIZE/2; mask > 0; mask >>= 1)  
        local_sum += __shfl_xor(local_sum, mask);  
  
    if (threadIdx.x%32==0)  
        out[blockIdx.x*blockDim.x/WARP_SIZE+threadIdx.x/WARP_SIZE];  
}
```



Loop 1
mask = 4 (100b)

Loop 2
mask = 2 (010b)

Loop 3
mask = 1 (001b)

- 归约算法
- 扫描算法

- 以下名称通常均指扫描算法
 - 扫描 (scan)、前缀扫描 (prefix scan)、前缀求和 (prefix sum)、并行前缀求和 (parallel prefix sum)
- 扫描是许多并行算法的基本组成模块
 - 基数排序 (radix sort)
 - 快速排序 (quick sort)
 - 流压缩 (stream compaction) 和流拆分 (stream split)
 - 计算直方图 (histogram)
 - 尽管扫描在串行算法中往往是不必要的!

为什么需要扫描？


– 以下算法都面临同一个问题：数据输出的位置

- 直方图分类例子


- 分配足够大的空间
- 使用atomic决定输出位置

- 存在问题：


- 浪费空间、不保留元素在原数组中顺序



直方图分类 (binning)




压缩 (compact)



拆分 (split)

使用扫描解决输出位置问题

– 以压缩为例



– 输出位置 (writing index) 可由对数组 flag 的前缀求和得到

• 前缀求和定义

– 对于给定数组 $A = [a_0, a_1, \dots, a_{n-1}]$ 及二元操作符 \oplus , 求:

$$\text{Scan}(A) = [0, a_0, (a_0 \oplus a_1), \dots, (a_0 \oplus a_1 \oplus \dots \oplus a_{n-1})]$$

串行前缀求和

– 例子：给定数组 $A = [2, 4, 5, 1, 3]$ 并使用整型求和

• $\text{Scan}(A) = [0, 2, 2+4, 2+4+5, 2+4+5+1]$

• $\text{Scan}(A) = [0, 2, 6, 11, 12]$

– 代码样例：

```
int A[5] = {2, 4, 5, 1, 3}
int scan_A[5];

int running_sum = 0;
for(int i = 0; i < 5; ++i){
    scan_A[i] = running_sum;
    running_sum += A[i];
}
```

使用扫描解决压缩算法输出位置问题


– 串行示意代码

```
int data[8] = {10, 0, 3, 9, 2, 0, 1, 2};
int flag[8];
int writing_index[8];
int running_sum = 0;

for(int i = 0; i < 8; ++i){
    flag[i] = (data[i] != 0);
}

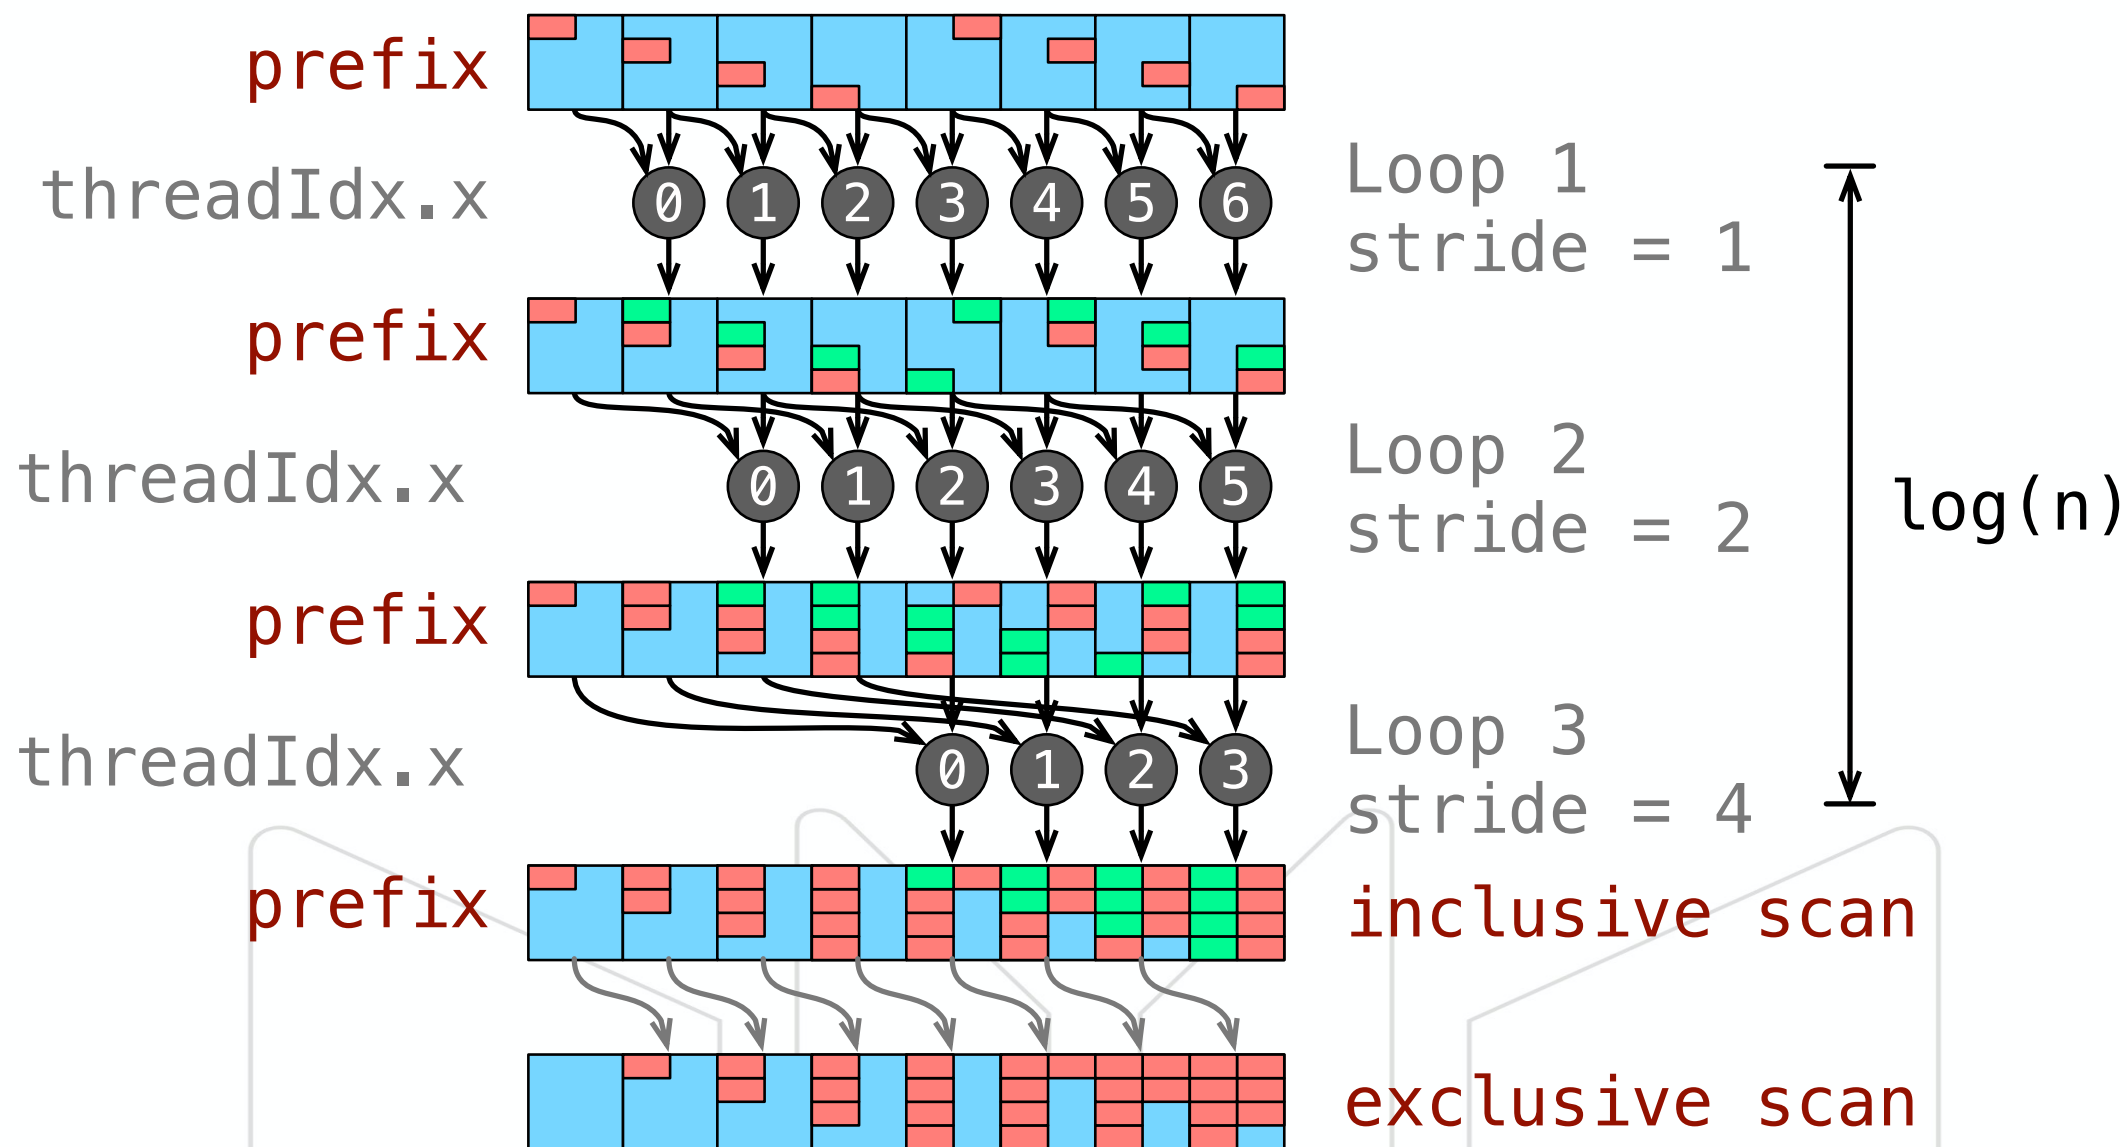
for(int i = 0; i < 8; ++i){
    writing_index[i] = running_sum;
    running_sum += flag[i];
}

int* compacted_data = new int[running_sum];
for(int i = 0; i < 8; ++i){
    if (flag[i]){
        compacted_data[writing_index[i]] = data[i];
    }
}
```



并行扫描算法（线程块）

– 包容性扫描与排他性扫描



并行扫描算法（线程块）

- 使用 **__syncthreads()** 同步线程块内的线程
- 无存储体冲突

```
__global__ void scan(int* data){
    extern __shared__ int s_data[];
    int tid = blockIdx.x*blockDim.x+threadIdx.x;
    s_data[threadIdx.x] = data[tid];

    for(int stride = 1; stride < blockDim.x; stride<=1){
        __syncthreads();
        int val = (threadIdx.x>=stride)?s_data[threadIdx.x-stride]:0;
        __syncthreads();
        s_data[threadIdx.x] += val;
    }
    //output
}
```

并行扫描算法（线程块）

- 使用 **__syncthreads()** 同步线程块内的线程
- 无存储体冲突

```
__global__ void scan(int* data){
    extern __shared__ int s_data[];
    int tid = blockIdx.x*blockDim.x+threadIdx.x;
    s_data[threadIdx.x] = data[tid];

    for(int stride = 1; stride < blockDim.x; stride<=1){
        __syncthreads();
        int val = (threadIdx.x>=stride)?s_data[threadIdx.x-stride]:0;
        __syncthreads();
        s_data[threadIdx.x] += val;
    }
    //output
}
```

是否可用以下代码替代？

```
if (threadIdx.x>=stride){
    s_data[threadIdx.x]+=s_data[threadIdx.x-stride];
}
```

并行扫描算法（线程块）

- 使用 **__syncthreads()** 同步线程块内的线程
- 无存储体冲突

```
__global__ void scan(int* data){  
    extern __shared__ int s_data[];  
    int tid = blockIdx.x*blockDim.x+threadIdx.x;  
    s_data[threadIdx.x] = data[tid];  
  
    for(int stride = 1; stride < blockDim.x; stride<=1){  
        __syncthreads();  
        int val = (threadIdx.x>=stride)?s_data[threadIdx.x-stride]:0;  
        __syncthreads();  
        s_data[threadIdx.x] += val;  
    }  
    //output  
}
```


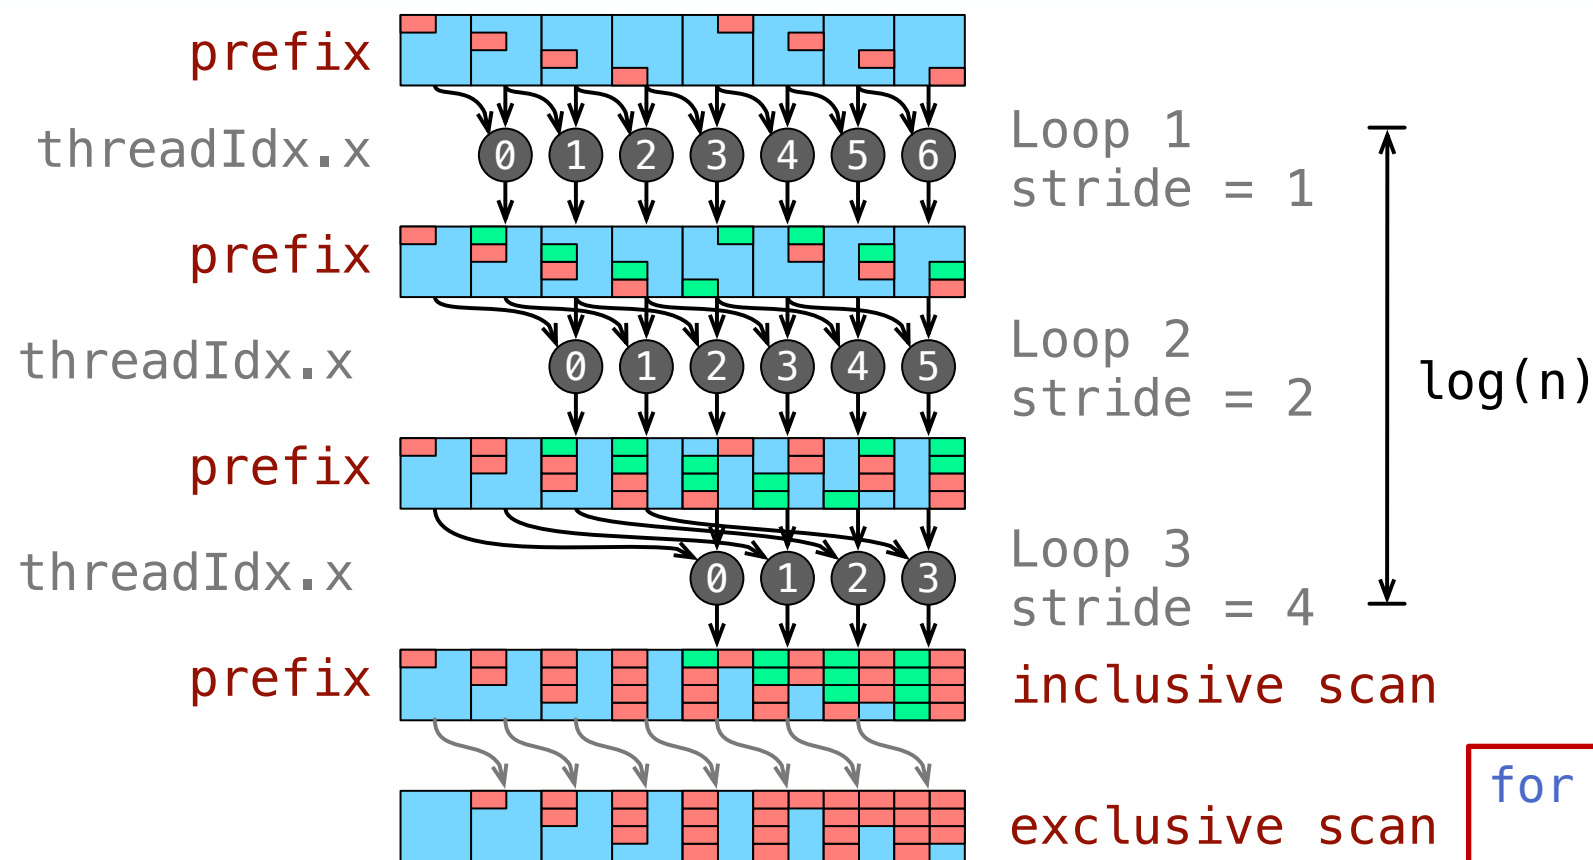
是否可用以下代码替代？

```
if (threadIdx.x>=stride){  
    s_data[threadIdx.x]+=s_data[threadIdx.x-stride];  
    __syncthreads();  
}
```


并行扫描算法（线程束）

– 对比扫描算法与之前的使用线程束的归约算法

- stride变化的顺序是否重要？



```
for (int stride = WARP_SIZE/2;  
     stride > 0; stride>>=1)  
{  
    local_sum += __shfl_down(local_sum, stride);  
}
```

并行扫描算法（线程束）

- 不需要分配共享内存
- 不需要同步

```
__global__ void scan(int* data){  
    int tid = blockIdx.x*blockDim.x+threadIdx.x;  
    int val1 = data[tid], val2;  
  
    for(int stride = 1; stride < 32; stride<=1){  
        val2 = __shfl_up(val1, stride);  
        if (threadIdx.x % 32 >= stride)  
            val1 += val2;  
    }  
    //output  
}
```

并行扫描算法（线程束）

- 不需要分配共享内存
- 不需要同步

```
__global__ void scan(int* data){
    int tid = blockIdx.x*blockDim.x+threadIdx.x;
    int val1 = data[tid], val2;

    for(int stride = 1; stride < 32; stride<=1){
        val2 = __shfl_up(val1, stride);
        if (threadIdx.x % 32 >= stride)
            val1 += val2;
    }
    //output
}
```

是否可用以下代码替代？

```
if (threadIdx.x % 32 >= stride){
    val1 += __shfl_up(val1, stride);
}
```

并行扫描算法（线程束）

- 不需要分配共享内存
- 不需要同步

```
__global__ void scan(int* data){
    int tid = blockIdx.x*blockDim.x+threadIdx.x;
    int val1 = data[tid], val2;

    for(int stride = 1; stride < 32; stride<=1){
        val2 = __shfl_up(val1, stride);
        if (threadIdx.x % 32 >= stride)
            val1 += val2;
    }
    //output
}
```

CUDA 9.0后可使用

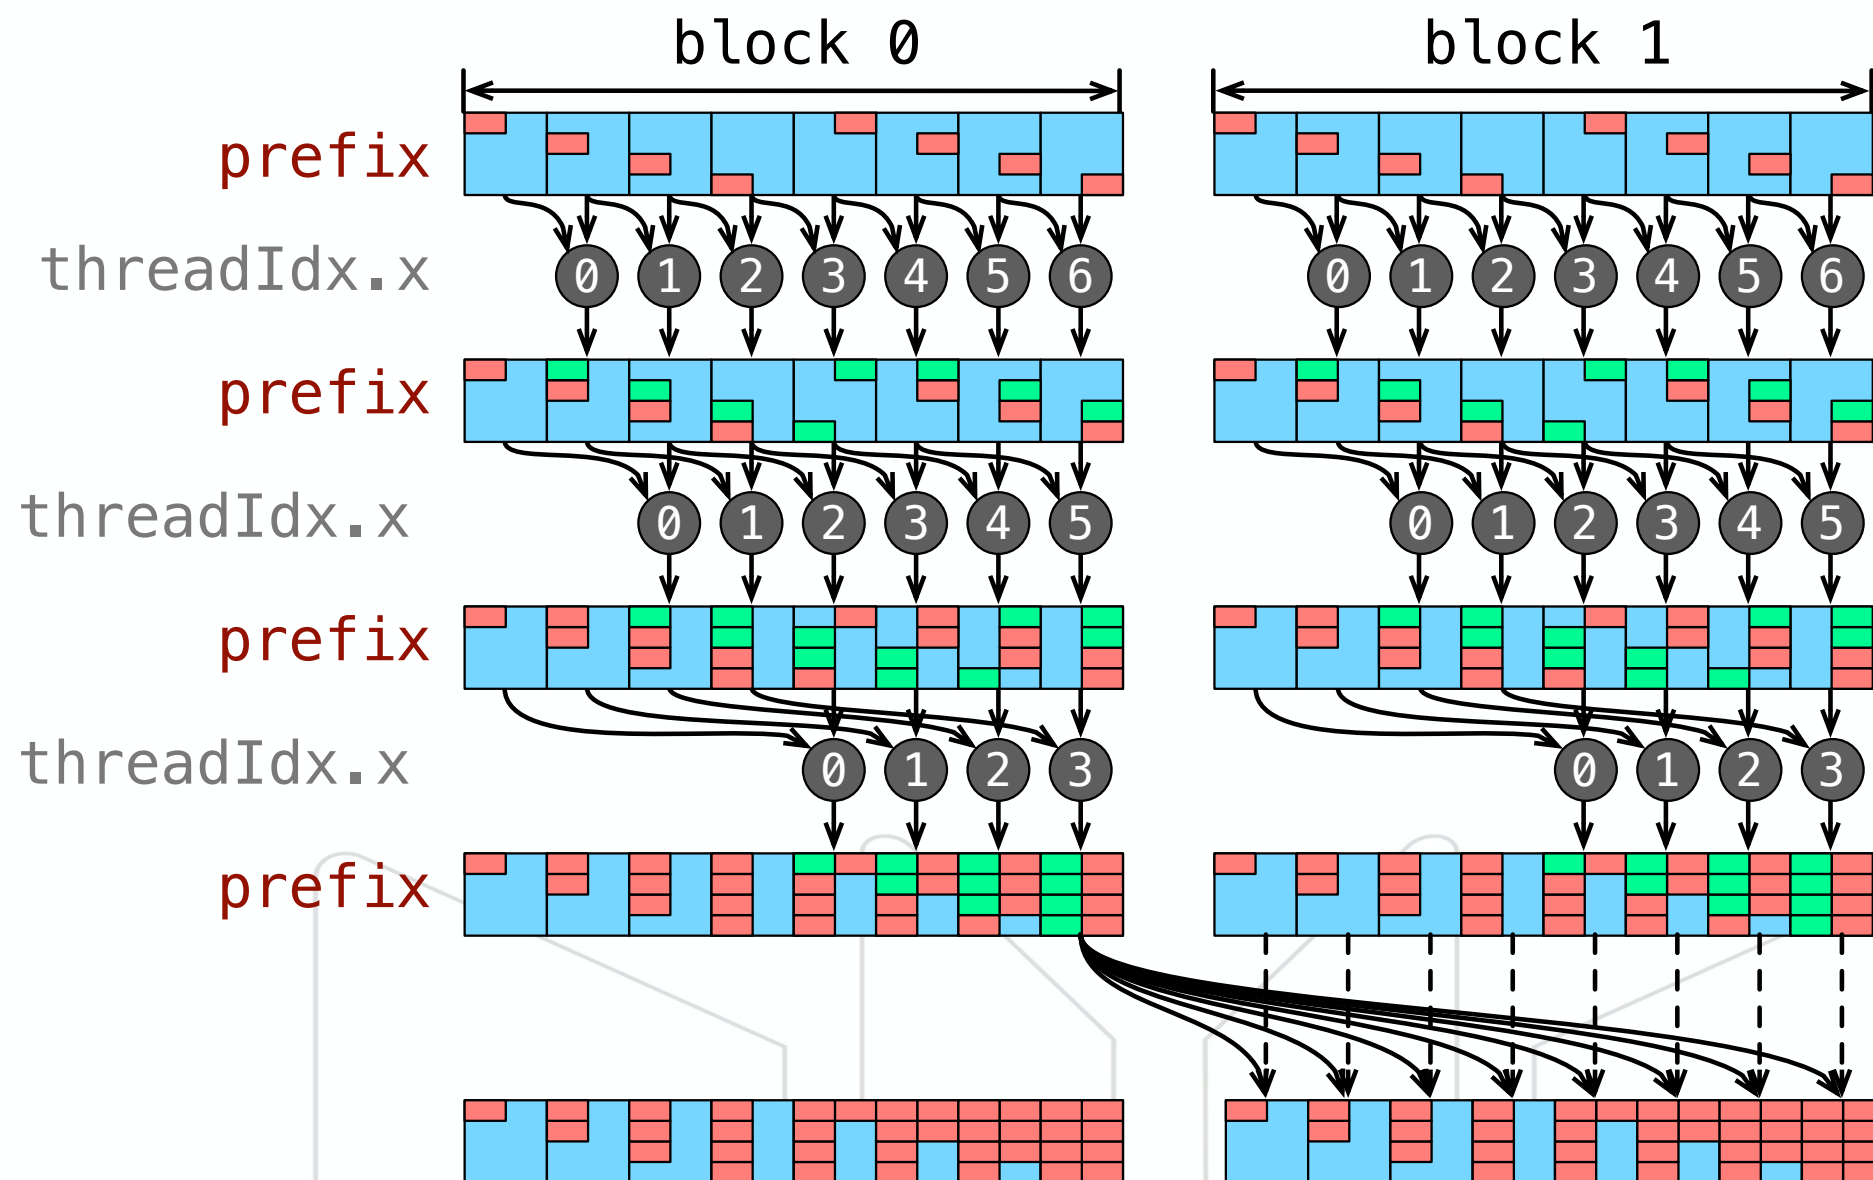
`__shfl_up_sync(mask, val1, stride);`

mask指明参与交换的线程

0xffffffff表明所有线程都参与交换

并行扫描算法（全局）

- 需要将每个线程块的局部总和加到其后的所有线程块的计算结果中



并行扫描算法（全局）

- 需要将每个线程块的局部总和加到其后的所有线程块的计算结果中
 - 同样需要一次前缀求和
 - 可迭代调用前缀求和核函数完成
 - 使用原子操作完成串行前缀求和

```
__global__ void scan(int* out, int* block_sums, int* data){
    extern __shared__ int s_data[];
    int tid = blockIdx.x*blockDim.x+threadIdx.x;
    s_data[threadIdx.x] = data[tid];

    for(int stride = 1; stride < blockDim.x; stride<=1){
        __syncthreads();
        int val = (threadIdx.x>=stride)?s_data[threadIdx.x-stride]:0;
        __syncthreads();
        s_data[threadIdx.x] += val;
    }

    out[tid] = s_data[threadIdx.x];
    if (threadIdx.x==0)
        for(int i=blockIdx.x+1; i<gridDim.x; ++i)
            atomicAdd(&block_sums[i], s_data[blockDim.x-1])
}
```

并行扫描算法（全局）

- 需要将每个线程块的局部总和加到其后的所有线程块的计算结果中
 - 使用原子操作：更新局部结果为全局结果
 - 加入block_sums

```
__global__ void scan_update(int* out, int* block_sums){  
    extern __shared__ int block_sum;  
    int idx = blockIdx.x*blockDim.x+threadIdx.x;  
  
    if (threadIdx.x == 0)  
        block_sum = block_sums[blockIdx.x];  
  
    __syncthreads();  
  
    out[idx] += block_sum;  
}
```

- 为什么要学习并行模式？
- 两种常见的并行模式
 - 归约：将数组中数据归约为一个元素
 - 迭代调用核函数
 - 在核函数内添加循环完成
 - 减少数据在缓存与全局内存中的移动
 - 扫描：前缀求和
 - 多种算法的基础
 - 同样可以迭代调用核函数或在核函数内添加循环完成
 - 高效的程序需要从网格、线程块、线程束三个层面进行优化
 - 原子操作可用于对线程块的结果进行归约/扫描

Questions?

